Practice 7: Single Variable model for regression

Loading data into R

```
PRSA_data <- read.csv("PRSA_data.csv")
```

```
## Rows: 43,824
## Columns: 13
## $ No    <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18...
## $ year  <int> 2010, 2010, 2010, 2010, 2010, 2010, 2010, 2010, 2010, 2010, 2...
## $ month <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1...
## $ day   <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1...
## $ hour  <int> 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17,...
## $ pm2.5 <int> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N...
## $ DEWP  <int> -21, -21, -21, -21, -20, -19, -19, -19, -19, -20, -19, -18, -...
## $ TEMP  <dbl> -11, -12, -11, -14, -12, -10, -9, -9, -9, -8, -7, -5, -5, -3,...
## $ PRES  <dbl> 1021, 1020, 1019, 1019, 1018, 1017, 1017, 1017, 1017, 1017, 1...
## $ cbwd  <chr> "NW", "NW", "NW", "NW", "NW", "NW", "NW", "NW", "NW", "NW", "...
## $ Iws   <dbl> 1.79, 4.92, 6.71, 9.84, 12.97, 16.10, 19.23, 21.02, 24.15, 27...
## $ Is    <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
## $ Ir    <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
```

PRSA dataset: 2010년 1월1일부터 2014년 12월 31일까지의 중국 베이징의 미세먼지 농도 및 날씨 정보

PRSA dataset: Fine dust concentration level and weather record of Beijing China from 2010-Jan-01 ~ 2014-Dec-31

variable	description
No	Row Index
year	관측연도
month	관측월
day	관츨일
hour	관측시간 0h ~ 23h
pm2.5	미세먼지 농도 Fine dust concentration (ug/m^3)
DEWP	Dew Point (이슬점)
TEMP	Temperature (기온)
PRES	Air pressure (기압) hPa
cbwd	Wind Direction (풍향)
Iws	Cumulated wind speed (m/s) (누적 풍속)
Is	Snowfall per hour (시간당 누적 강설량)
Ir	precipitation per hour(시간당 누적 강수량)

Question 1

미세먼지 농도(**pm2.5**)를 예측하는 Single Variable Regression 모델을 만들어보려고 한다.

가장 먼저 전체 데이터를 train과 test 용도로 분할한다.

- 2010년부터 2013년 데이터를 train 데이터로 하고, 2014년 데이터를 test 데이터로 분할하여라.
- 그리고 목적 변수인 pm2.5 값에 NA인 것이 있다면 삭제하고 필요한 전처리 과정이 있다면 수행하여라.
- train 데이터와 test 데이터의 sample 수는 어떻게 나누어졌으며 비율은 어떠한가?
- train 데이터의 pm2.5 값과 test 데이터의 pm2.5 값의 분포(평균, 분산)를 비교하여 보고 비슷한지 확인하여라.

We build a prediction model to predict the fine dust concentration(**pm2.5**) using single variable.

First, we partition the dataset into two, one for training model and one for testing.

- Use the dataset from year of 2010 to 2013 for train, the rest of year 2014 for testing.
- If we have missing values in our target variable **pm2.5**, remove those NAs and perform any necessary data-preparation.
- What are the ratio of the number of samples for training and testing?
- compare the distribution of variable **pm2.5** in training and testing dataset in terms of mean and variance. do you find their distribution are almost identical?

distribution of pm2.5 in both datasets

```
##       Min.    1st Qu.     Median       Mean    3rd Qu.       Max.        var
##    0.00000   29.00000   73.00000   98.84315  138.00000  994.00000 8401.34863
```

```
##       Min.    1st Qu.     Median       Mean    3rd Qu.       Max.        var
##    2.00000   28.00000   72.00000   97.73456  133.00000  671.00000 8748.14674
```

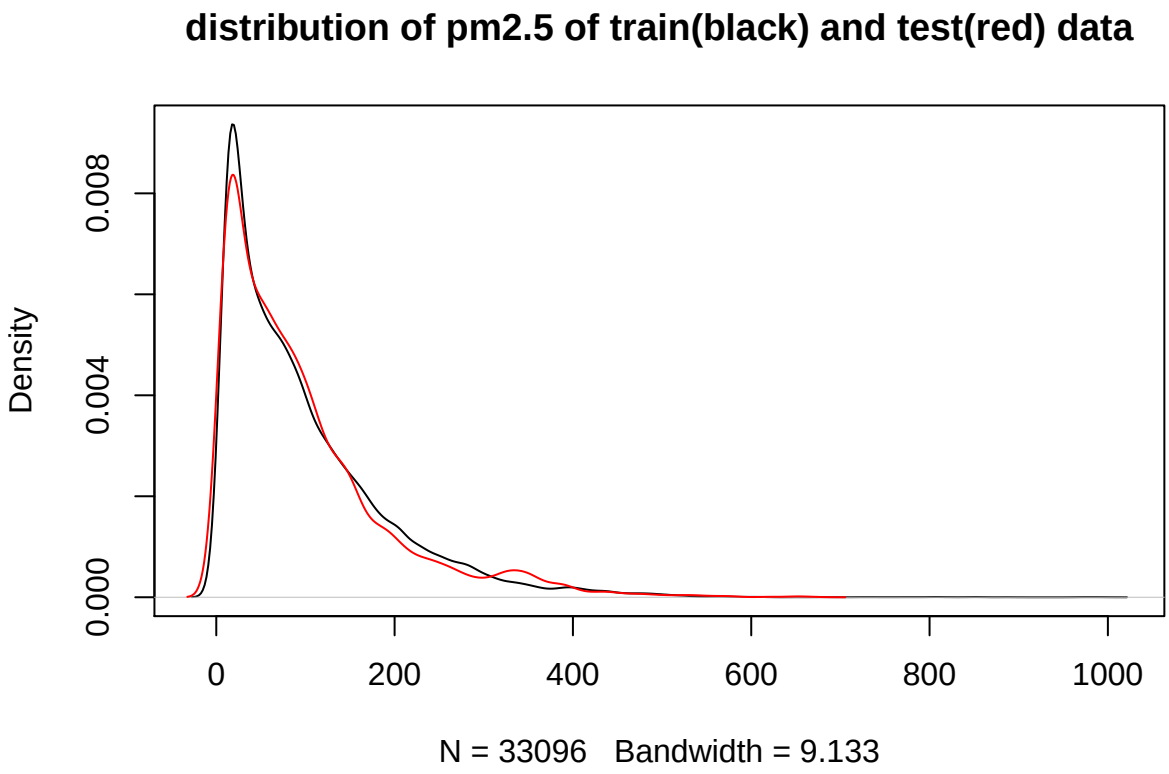
distribution of pm2.5 of train(black) and test(red) data
Density
0.000
0.004
0.008
0
200
400
600
800
1000
N = 33096 Bandwidth = 9.133

Question 2-1

month를 사용하여 pm2.5를 예측하는 단일 변수 모델(single variable model)을 만들어라.

예측한 pm2.5 값과 실제 값과의 차이를 error(residual)로 데이터에 추가하여라

Build a single variable model to predict **pm2.5** using the variable **month**.

add predicted pm2.5 and their error (residual = actual value - predicted value) to the dataset.

Sample Result

```
##    month pm2.5     pred     error
## 1      1   129 114.1159 14.884053
## 2      1   148 114.1159 33.884053
## 3      1   159 114.1159 44.884053
## 4      1   181 114.1159 66.884053
## 5      1   138 114.1159 23.884053
## 6      1   109 114.1159 -5.115947
## 7      1   105 114.1159 -9.115947
## 8      1   124 114.1159  9.884053
## 9      1   120 114.1159  5.884053
## 10     1   132 114.1159 17.884053
```

Question 2-2

Question 2-1에서 구한 모델의 MSE와 RMSE 구하라

이 모델을 test data에도 적용하여 MSE와 RMSE를 구하라라

Find the MSE and RMSE for the prediction model we found in Question 2-1.

Find the MSE and RMSE for the test dataset as well as training dataset.

sample result

```
## [1] "train data: (MSE 8254.242) (RMSE 90.853)"
## [1] "test data : (MSE 8397.312) (RMSE 91.637)"
```

Question 2-3

Question 2-1에서 구한 모델을 적용하여 train data와 test data의 R^2 값을 구하고,

그것을 바탕으로 만들어진 단일변수 모델이 pm2.5의 변동을 얼마나 잘 설명하고 있는지 이야기해보자.

Find the R^2 of model from Question 2-1 for both train and test dataset.

Explain how well your model predicts the variance of pm2.5 using R^2.

R^2 for train dataset and test dataset

```
## [1] "R2 for train data: 0.017"
## [1] "R2 for test data: 0.040"
```

Question 3

hour 변수를 사용해서 Question 2번의 과정을 반복하라.

hour를 어떤 구간으로 나누어서 모델은 만드는 것이 효과적인가?

Repeat the question 2-1 ~ 2-3 using variable of **hour**.

What would be the best way to categorize **hour** to train prediction model.

Question 4

동일한 과정을 DEWP 변수를 사용해서 수행하라.

Repeat the question 2-1 ~ 2-3 using variable of **DEWP**.

Question 5

위에서 시도한 다양한 단일 변수 모델 중 어떤 모델이 가장 예측 성능이 뛰어난가?

예측 성능이 높은 이유가 무엇인지 생각해보자.

Among those attempts above, which model was the best to predict **pm2.5**.

State your idea why the model outperforms others?